

¿Cuánto Mejora Realmente el Aprendizaje Automático la Predicción del Riesgo de Diabetes a partir de Indicadores de Salud Poblacional? Un *Benchmark* Honesto, Interpretable y Reproducible sobre BRFSS 2015

G. Álvarez Sánchez, J. Javier Moya Moya, I. Peredo Valderrama, J. Pacindo Piña, D. Fernandez Conde
Estudio Diabetes Health Indicators (CDC BRFSS 2015)

Resumen—El aprendizaje automático (*Machine Learning*, ML) se promueve ampliamente para la predicción del riesgo de diabetes a nivel poblacional, a menudo con afirmaciones de grandes mejoras sobre los modelos clásicos. Ponemos a prueba estas afirmaciones de forma rigurosa sobre el conjunto *Diabetes Health Indicators* de los CDC (BRFSS 2015; $n = 253,680$; prevalencia 13.9%), un escenario de cribado prelaboratorio libre de fuga que contiene solo indicadores de encuesta autorreportados. Bajo un único protocolo uniforme—partición estratificada 60/20/20, búsqueda aleatorizada de hiperparámetros, transformadores ajustados dentro de los pliegues de entrenamiento y ordenación libre de umbral por ROC-AUC—comparamos nueve estimadores y cuantificamos la incertidumbre con intervalos de confianza *bootstrap* (1000 remuestreos) sobre el conjunto de prueba retenido. El mejor modelo (*histogram gradient boosting* / XGBoost) alcanza ROC-AUC = 0.827 [0.822, 0.832]; la regresión logística regularizada con ℓ_2 alcanza 0.820 [0.815, 0.824]. La diferencia emparejada es de apenas $\Delta\text{AUC} = 0.007$ (IC *bootstrap* [0.006, 0.009]): estadísticamente detectable dada la gran muestra, pero prácticamente despreciable, mientras que los principales modelos de *boosting* son mutuamente indistinguibles. Nueve sesgos inductivos muy distintos se saturan cerca de ROC-AUC ≈ 0.83 , evidenciando una *meseta* de desempeño impuesta por el contenido de información de las variables, no por la elección del algoritmo. Mostramos además que la exactitud ($0.866 \approx$ la base mayoritaria 0.861) es engañosa; que la calibración isotónica produce probabilidades confiables (error de calibración esperado 0.003); y que una estratificación de riesgo en cuatro niveles, sensible al costo y derivada de la calibración, separa la prevalencia observada por un factor de 16 ($2.9\% \rightarrow 48.0\%$; razón de momios 30.7, IC 95% [28.0, 33.6]) en datos retenidos. De forma crítica, admitir biomarcadores diagnósticos modificaría el AUC en ≈ 0.15 —unas veinte veces la brecha entre modelos—por lo que controlar la fuga de información importa mucho más que cambiar de modelo. La evaluación honesta, la calibración, la interpretabilidad y la reproducibilidad aportan así más valor clínico que la exactitud marginal, y estos modelos apoyan el cribado, no el diagnóstico.

Palabras clave—predicción de riesgo de diabetes, aprendizaje automático, BRFSS, calibración, IA explicable, SHAP, fuga de información, modelos de predicción clínica, reproducibilidad.

I. INTRODUCCIÓN

La diabetes tipo 2 es una de las enfermedades crónicas más prevalentes del mundo y la identificación temprana de personas

en riesgo es una prioridad de salud pública [1], [2]. La amplia disponibilidad de encuestas poblacionales de salud, junto con la popularidad de los árboles potenciados por gradiente y las redes profundas, ha producido una extensa literatura que reporta modelos de ML para la predicción de diabetes [3]–[6]. Una narrativa recurrente es que los modelos modernos y no lineales ofrecen mejoras sustanciales sobre la regresión logística clásica. Sin embargo, una revisión sistemática de modelos de predicción clínica no encontró *ningún* beneficio consistente del ML sobre la regresión logística cuando los estudios se evalúan de forma justa [7]. Esta tensión motiva un reexamen cuidadoso y reproducible de *cuánto* ayuda realmente el ML cuando las entradas son indicadores de salud ordinarios y autorreportados.

Abordamos la pregunta: *¿hasta qué punto los modelos modernos de ML mejoran realmente la predicción de diabetes a partir de indicadores de salud poblacional?* Investigamos cuatro hipótesis: (H1) los modelos complejos no superan significativamente a una línea base lineal bien regularizada; (H2) existe una meseta de desempeño observable impuesta por las variables disponibles; (H3) la interpretabilidad puede aportar más valor clínico que pequeñas mejoras de exactitud; y (H4) el control riguroso de la fuga de información cambia sustancialmente el desempeño aparente de los modelos de diabetes.

De forma crucial, BRFSS no contiene *ninguna* medición de laboratorio diagnóstica (p. ej. HbA1c, glucosa en ayunas). Es, por tanto, un genuino escenario de *cribado prelaboratorio*, libre de la fuente más común de sesgo optimista en el ML de diabetes—usar criterios diagnósticos como predictores [8], [9]. Esto convierte al conjunto de datos en un banco de pruebas ideal para un análisis *honesto* de la meseta predictiva.

Nuestras contribuciones son: (1) un *benchmark* uniforme y consciente de la fuga de nueve estimadores sobre un gran conjunto público; (2) una demostración cuantitativa de una meseta predictiva y de la cuasi-equivalencia de modelos lineales y no lineales; (3) un análisis de calibración y explicabilidad que muestra dónde reside el verdadero valor clínico; y (4) una tubería totalmente reproducible con todas las métricas, figuras

y artefactos. El artículo deliberadamente *no* trata sobre ningún producto de software particular; los protagonistas son el conjunto de datos, los modelos y los hallazgos científicos.

II. TRABAJO RELACIONADO

Predicción de diabetes a partir de encuestas. Xie *et al.* [3] construyeron modelos de riesgo de diabetes tipo 2 sobre BRFSS 2014 y reportaron valores de ROC-AUC en el rango bajo-medio de 0.8, con redes neuronales y *ensembles* que ofrecían ganancias modestas sobre modelos más simples. Dinh *et al.* [4] alcanzaron una discriminación comparable sobre NHANES, y Tigga y Garg [5] exploraron clasificadores clásicos sobre datos de cuestionario. Estos resultados son ampliamente consistentes con una banda de desempeño que nuestro estudio hace explícita y cuantifica.

ML frente a regresión logística. Christodoulou *et al.* [7] revisaron 71 comparaciones y no hallaron beneficio de desempeño del ML sobre la regresión logística para predicción clínica, advirtiendo sobre la evaluación optimista. Steyerberg [10] enfatiza la validación y la calibración por encima de la discriminación bruta. Nuestros hallazgos corroboran estas conclusiones en un *benchmark* grande y moderno.

Calibración. Las probabilidades bien calibradas son esenciales para las decisiones clínicas [11], [12]. Guo *et al.* [13] mostraron que los modelos modernos suelen estar mal calibrados; el escalamiento isotónico y de Platt son remedios estándar. Evaluamos ambos.

Interpretabilidad. SHAP [14], [15] y LIME [16] proporcionan atribuciones *post-hoc*, mientras que Rudin [17] y Caruana *et al.* [18] abogan por modelos inherentemente interpretables en contextos de alto riesgo; sin embargo, Ghassemi *et al.* [19] advierten contra la confianza excesiva en las explicaciones *post-hoc* en salud. Usamos SHAP e importancia por permutación para caracterizar la señal predictiva.

Fuga e imbalance. La fuga de datos es una causa principal de ML irreproducible en ciencia [8], [9]; el imbalance de clases hace que la exactitud sea engañosa y motiva métricas libres de umbral y basadas en rango [20]–[22]. Ambas preocupaciones son centrales en nuestro protocolo.

III. DESCRIPCIÓN DEL CONJUNTO DE DATOS

A. Origen y tamaño

Usamos el conjunto *Diabetes Health Indicators* [23], una extracción curada del *Behavioral Risk Factor Surveillance System* (BRFSS) 2015 de los CDC, una encuesta telefónica de salud anual de EE. UU. [24]. El archivo de objetivo binario contiene 253,680 encuestados y 21 variables predictoras más el objetivo `Diabetes_binary`. El conjunto no tiene valores faltantes; 24,206 filas (9.5%) son duplicados exactos, que se *conservan* porque vectores de respuesta categóricos idénticos de encuestados distintos son esperables y eliminarlos sesgaría la prevalencia.

B. Distribución de clases

El objetivo indica diabetes diagnosticada. La prevalencia del cohorte es de 13.9% positivos frente a 86.1% negativos,




Fig. 1. Distribución de clases del objetivo binario (izquierda, prevalencia 13.9%) y el gradiente natural de riesgo en la variante de tres clases (derecha: sin diabetes / prediabetes / diabetes). El marcado imbalance hace de la exactitud una métrica poco fiable.

Tabla I
CARACTERÍSTICAS DEL CONJUNTO DE DATOS (ARCHIVO BINARIO BRFSS 2015).

Propiedad	Valor
Encuestados (n)	253,680
Variables predictoras	21 (todas codificadas numéricamente)
Objetivo	<code>Diabetes_binary</code> (0/1)
Prevalencia de positivos	13.9%
Razón de imbalance	6.18:1
Valores faltantes	0
Filas duplicadas	24,206 (9.5%, conservadas)
Variables de laboratorio diagnóstico	ninguna (escenario de cribado)

una razón de imbalance de 6.18:1 (Fig. 1). Esta prevalencia poblacional real—en lugar de una submuestra artificialmente balanceada—se preserva en todo el estudio, porque las cantidades epidemiológicas (prevalencia, razones de momios, riesgos relativos) y las probabilidades calibradas solo tienen sentido a la tasa base verdadera.

C. Variables

Las 21 predictoras están codificadas numéricamente y se agrupan en cinco dominios clínicos: *cardiometaabólico* (HighBP, HighChol, CholCheck, BMI, Stroke, HeartDiseaseorAttack); *conductual* (Smoker, PhysActivity, Fruits, Veggies, HvyAlcoholConsump); *funcional/salud general* (GenHlth, MentHlth, PhysHlth, DiffWalk); *socioeconómico/acceso* (AnyHealthcare, NoDocbcCost, Education, Income); y *demográfico* (Sex, Age). La Tabla I resume el conjunto. Notablemente, *no* hay ningún valor de laboratorio diagnóstico, lo que es la clave de una evaluación de cribado libre de fuga (Sección VII).

D. Señal univariada

Las correlaciones de Pearson más fuertes con el objetivo son la percepción de salud general (GenHlth, $r = 0.29$), la hipertensión ($r = 0.26$), la dificultad para caminar ($r = 0.22$), el índice de masa corporal ($r = 0.22$), el colesterol alto ($r = 0.20$) y la edad ($r = 0.18$). Todas las correlaciones individuales son de débiles a moderadas, una indicación temprana de que ningún ítem de encuesta por sí solo posee un poder predictivo fuerte.

E. Limitaciones y posibles sesgos

BRFSS es una encuesta telefónica transversal y autorreportada y, por tanto, sujeta a sesgo de memoria, sesgo de deseabilidad social, sesgo de no respuesta y sesgo de cobertura (muestreo de línea fija/móvil). El desenlace es un diagnóstico médico autorreportado, no una confirmación bioquímica, por lo que los casos no diagnosticados se etiquetan erróneamente como negativos—atenando las asociaciones medidas. Las variables están toscamente cuantizadas (p. ej. la edad en 13 rangos, el ingreso en 8 bandas). Estas propiedades acotan la señal alcanzable y deben moderar cualquier afirmación de desempeño.

IV. METODOLOGÍA

A. Protocolo y control de fuga

Aplicamos un único protocolo uniforme a todos los modelos. Las variables se usaron exactamente como vienen; las numéricas/ordinales se estandarizaron y las binarias se pasaron sin cambios. Los datos se dividieron por muestreo estratificado en 60% entrenamiento, 20% validación y 20% prueba (50,736 encuestados de prueba), preservando la prevalencia. Como el conjunto contiene solo indicadores de encuesta, el experimento es intrínsecamente libre de fuga respecto a criterios diagnósticos; además evitamos la fuga de objetivo en el preprocesamiento ajustando todos los transformadores únicamente dentro de los pliegues de entrenamiento.

B. Modelos y ajuste

Entrenamos nueve estimadores que abarcan las familias lineal, basada en instancias, de *kernel*, de árboles y neuronal: regresión logística (LR) [25], *random forest* (RF) [26], *extremely randomized trees* (ET), *histogram gradient boosting* (HGB) [27], XGBoost [28], LightGBM [29], un perceptrón multicapa (MLP), *k*-vecinos más cercanos (KNN) [30] y una máquina de vectores de soporte (SVM) [31]. Cada modelo se ajustó con búsqueda aleatorizada sobre un espacio específico usando validación cruzada estratificada de 3 pliegues en la partición de entrenamiento, optimizando ROC-AUC. SVM y KNN se ajustaron sobre submuestras estratificadas por tratabilidad; esto afecta solo a esos dos modelos y se reporta de forma transparente.

C. Métricas

Debido al imbalance de clases, ordenamos los modelos por el ROC-AUC libre de umbral y reportamos PR-AUC, el coeficiente de correlación de Matthews (MCC) [22], la exactitud equilibrada, F_1 , precisión, sensibilidad (*recall*), especificidad, exactitud y el puntaje de Brier. Por el imbalance enfatizamos que los puntos de operación se abordan adecuadamente mediante el análisis de estratificación de riesgo (Sección V-C), no mediante la exactitud bruta.

D. Comparación estadística

Para no afirmar diferencias no sustentadas por los datos, cuantificamos la incertidumbre en lugar de ordenar solo por estimaciones puntuales. Para cada modelo estimamos un

intervalo de confianza del 95% del ROC-AUC de prueba remuestreando el conjunto de prueba con reemplazo (1000 réplicas *bootstrap*). Para comparar dos modelos usamos el *bootstrap emparejado* de la diferencia de AUC (mismos índices remuestreados para ambos modelos), que es robusto y respeta la estructura emparejada de las predicciones [32]. Interpretamos una diferencia como prácticamente relevante solo si su magnitud—no meramente su significancia—es no trivial, una distinción que importa precisamente porque el gran conjunto de prueba hace que brechas sub-porcentuales sean estadísticamente detectables.

E. Calibración y estratificación

El modelo seleccionado se calibró con escalamiento de Platt y regresión isotónica, evaluado por el puntaje de Brier y el error de calibración esperado (ECE). A partir de las probabilidades calibradas derivamos una estratificación de riesgo clínico en cuatro niveles y la validamos en el conjunto de prueba intacto (Sección V-C). La interpretabilidad usó SHAP [14], [15] e importancia por permutación.

V. RESULTADOS EXPERIMENTALES

A. Comparación de modelos

La Tabla II reporta todas las métricas sobre la partición de prueba retenida, ordenadas por ROC-AUC, con intervalos de confianza *bootstrap* del 95%; la Fig. 2 superpone las curvas ROC. *Histogram gradient boosting* y XGBoost empatan por la mejor discriminación (ROC-AUC = 0.827, IC [0.822, 0.832]), con LightGBM (0.827), *random forest* (0.824) y el MLP (0.823) muy cerca. La regresión logística regularizada alcanza 0.820 [0.815, 0.824]—solo 0.007 AUC por debajo del mejor modelo. KNN (0.795) y especialmente la SVM (0.683) quedan rezagados. Como referencia justa para el escenario imbalancedo, el PR-AUC del clasificador aleatorio es igual a la prevalencia (0.139); el mejor PR-AUC (0.424) es por tanto solo $\approx 3\times$ el azar, una declaración honesta de la modesta señal absoluta.

Para probar H1 de forma inferencial calculamos IC *bootstrap* emparejados de la diferencia de AUC (Sección IV-D). La brecha entre el mejor modelo y la regresión logística es $\Delta\text{AUC} = 0.007$ con un IC emparejado de [0.006, 0.009] que *excluye* el cero: la diferencia es *estadísticamente resoluble*—nada sorprendente con 50,736 casos de prueba—pero *prácticamente despreciable* (0.7 puntos de AUC). En cambio, los tres mejores modelos de *boosting* son mutuamente *indistinguibles* (p. ej. HGB vs. LightGBM, $\Delta\text{AUC} \approx 0$, IC [−0.0001, 0.0007], incluye el cero). Así, la lectura honesta de H1 no es “sin diferencia” sino “una diferencia demasiado pequeña para importar clínicamente,” que el gran n simplemente vuelve detectable.

Dos observaciones son decisivas. Primera, la *exactitud es poco informativa*: cada modelo basado en árboles reporta exactitud ≈ 0.866 , apenas por encima de la base mayoritaria de 0.861, lograda prediciendo a casi todos como negativos (sensibilidad 0.04–0.16 al umbral 0.5) [20], [21]. Segunda, las métricas sensibles al umbral exponen el comportamiento sensible al costo de la regresión logística, que usó reponderación

Tabla II

COMPARACIÓN DE MODELOS EN LA PARTICIÓN DE **PRUEBA** RETENIDA ($n = 50,736$), ORDENADA POR ROC-AUC, CON INTERVALOS DE CONFIANZA *bootstrap* DEL 95% (1000 REMUESTREOS) PARA ROC-AUC. LAS MÉTRICAS DEPENDIENTES DE UMBRAL USAN UN CORTE DE 0.5. EL MEJOR VALOR POR COLUMNA EN **NEGRITA**.

Modelo	ROC-AUC	IC 95%	PR-AUC	MCC	Exac. equil.	F_1	Precisión	Sensib.	Especif.	Brier
HistGradientBoosting	0.827	[0.822, 0.832]	0.423	0.246	0.568	0.244	0.566	0.156	0.981	0.097
XGBoost	0.827	[0.822, 0.831]	0.423	0.236	0.563	0.231	0.561	0.145	0.982	0.097
LightGBM	0.827	[0.822, 0.831]	0.424	0.247	0.570	0.250	0.556	0.161	0.979	0.097
Random Forest	0.824	[0.819, 0.829]	0.418	0.213	0.550	0.189	0.582	0.113	0.987	0.098
MLP	0.823	[0.819, 0.828]	0.412	0.224	0.559	0.217	0.552	0.135	0.982	0.098
Regresión Logística	0.820	[0.815, 0.824]	0.393	0.356	0.744	0.441	0.311	0.760	0.727	0.177
Extra Trees	0.819	[0.814, 0.824]	0.409	0.187	0.538	0.148	0.593	0.085	0.991	0.099
KNN	0.795	[0.790, 0.800]	0.360	0.149	0.528	0.115	0.535	0.065	0.991	0.102
SVM	0.683	[0.675, 0.691]	0.322	0.123	0.517	0.074	0.568	0.040	0.995	0.114




Fig. 2. Curvas ROC de los nueve modelos en la partición de prueba. Las curvas de los mejores modelos son casi coincidentes, ilustrando la meseta predictiva.

de clases y por tanto alcanza el mayor MCC (0.356), exactitud equilibrada (0.744), F_1 (0.441) y sensibilidad (0.760). En otras palabras, el único modelo genuinamente útil *en su umbral por defecto* es el lineal—una ilustración directa de H1 y H3.

B. Calibración

La Tabla III y la Fig. 3 muestran que el modelo potenciado por gradiente ya está bien calibrado (ECE de prueba = 0.0044, Brier = 0.097). La regresión isotónica lo mejora ligeramente (ECE = 0.0029, Brier = 0.097), mientras que el escalamiento de Platt degrada la calibración en esta gran muestra (ECE = 0.029). Por tanto adoptamos la calibración isotónica, obteniendo probabilidades adecuadas para umbralizar en bandas de riesgo clínico.

C. Estratificación de riesgo y validación clínica

Comparamos cuatro estrategias de umbralización fundamentadas—percentiles poblacionales, cuartiles,

Tabla III

CALIBRACIÓN DE PROBABILIDAD DEL MODELO SELECCIONADO (XGBOOST). ECE: ERROR DE CALIBRACIÓN ESPERADO (10 bins). MENOR ES MEJOR.

Variante	Brier (val)	ECE (val)	Brier (test)	ECE (test)
Original	0.0968	0.0040	0.0974	0.0044
Platt	0.0985	0.0257	0.0995	0.0285
Isotónica	0.0965	0.0000	0.0975	0.0029

Calibración: original vs Platt vs isotónica — xgboost (test)




Fig. 3. Diagrama de fiabilidad en el conjunto de prueba: original vs. Platt vs. isotónica. La calibración isotónica sigue la diagonal con mayor cercanía.

optimización por sensibilidad clínica basada en ROC y umbrales sensibles al costo (de Bayes)—por su capacidad de separar grupos de desenlace (η^2 , monotonía, tamaños de banda no triviales). La regla sensible al costo (umbrales 0.09/0.20/0.40 sobre la probabilidad calibrada) dio la mejor separación ($\eta^2 = 0.18$) y se validó en el conjunto de prueba intacto. La Tabla IV y la Fig. 4 reportan el resultado: la prevalencia observada crece monótonicamente de 2.9% (Bajo) a 48.0% (Muy Alto), un gradiente de 16.4 veces, con razones de momios respecto a la banda Baja de 5.5, 13.7 y

Tabla IV
VALIDACIÓN CLÍNICA DE LAS BANDAS DE RIESGO EN EL CONJUNTO DE PRUEBA RETENIDO ($n = 50,736$). OR/RR SON RESPECTO A LA BANDA BAJA.

Banda	n	Prevalencia	OR [IC 95%]	RR
Bajo	26,149	2.9%	1.0 (ref)	1.0
Moderado	11,877	14.2%	5.5 [5.0, 6.0]	4.9
Alto	7,844	29.1%	13.7 [12.5, 14.9]	10.0
Muy Alto	4,866	48.0%	30.7 [28.0, 33.6]	16.4




Fig. 4. Razones de momios (escala logarítmica, IC 95%) de cada banda de riesgo respecto a la banda Baja en el conjunto de prueba retenido. La escalada monótona confirma la separación clínica.

30.7 e intervalos de confianza estrechos. La Fig. 5 muestra la distribución poblacional entre bandas. Esto demuestra que, aunque la discriminación bruta está acotada, el modelo calibrado soporta una partición de riesgo clínicamente significativa y monótona—posiblemente la salida más valiosa.

D. Interpretabilidad

Las atribuciones SHAP sobre el modelo seleccionado (Fig. 6) y la importancia por permutación (Fig. 7) coinciden estrechamente. Los impulsores dominantes del riesgo predicho son la percepción de salud general, la hipertensión, el IMC, la edad y el colesterol alto; un mayor ingreso actúa de forma protectora, y la actividad física y el consumo de fruta/verdura reducen el riesgo. Estas atribuciones son clínicamente coherentes y recuperan la estructura de riesgo cardiometabólica y socioeconómica bien establecida de la diabetes tipo 2, proporcionando un relato transparente de *por qué* el modelo asigna riesgo—sin ningún paso de caja negra.

VI. DISCUSIÓN

A. ¿Por qué los modelos complejos no superan a la regresión logística?

Los cinco modelos más fuertes difieren en a lo sumo 0.003 AUC, y el mejor modelo no lineal supera a la regresión logística por solo 0.007. Esta cuasi-equivalencia indica que la señal predictiva en BRFS es en gran medida *aditiva* y *de bajo orden*: una vez capturados los principales efectos




Fig. 5. Distribución de la probabilidad calibrada de diabetes con las cuatro bandas de riesgo sensibles al costo. La mayoría de los encuestados cae en la banda Baja; una pequeña cola de alto riesgo concentra los casos verdaderos.




Fig. 6. Resumen SHAP (*beeswarm*) del modelo seleccionado. El color codifica el valor de la variable; la posición horizontal codifica el impacto en el riesgo predicho.

cardiometabólicos, demográficos y socioeconómicos, queda poca interacción o no linealidad explotable para los árboles o las redes. El resultado es plenamente consistente con la evidencia sistemática de Christodoulou *et al.* [7] y con la visión estadística de que los modelos flexibles ayudan solo cuando la superficie de respuesta verdadera es genuinamente no lineal [10].

B. ¿Cuál es la meseta de desempeño observada?

A través de nueve sesgos inductivos muy distintos, la discriminación se satura cerca de ROC-AUC ≈ 0.83 . Como esta meseta la alcanzan modelos de capacidad radicalmente distinta, se explica mejor por el *contenido de información* de




Fig. 7. Importancia por permutación (caída de ROC-AUC). El orden corrobora el análisis SHAP, aumentando la confianza en la señal identificada.

las entradas que por la elección del modelo: indicadores toscamente cuantizados y autorreportados, sin ninguna medición bioquímica, no codifican suficiente señal para separar casos de controles más allá de este nivel (H2). Deliberadamente la llamamos *meseta observada* para este conjunto de variables y población, no un techo absoluto: podría desplazarse con biomarcadores, medición más fina, datos longitudinales o un cohorte distinto. El punto es comparativo—ningún estimador la evade—más que una cota universal.

C. Implicaciones clínicas y epidemiológicas

La estructura de riesgo interpretable (Fig. 6) reproduce epidemiología conocida: hipertensión, obesidad, dislipidemia, edad y bajo nivel socioeconómico impulsan el riesgo, mientras que la actividad física y la dieta son protectoras. Para el soporte a la decisión, el artefacto accionable no es una etiqueta binaria sino la *probabilidad calibrada* y su mapeo a bandas de riesgo que escalan la prevalencia 16 veces (Tabla IV). En el punto de operación orientado a la inclusión, el modelo marca el $\approx 10\%$ superior de la población con 48% de prevalencia verdadera (VPP 0.48, especificidad 0.94), mientras que un punto orientado a la exclusión conserva $\approx 89\%$ de sensibilidad—apoyando el triaje en lugar del diagnóstico [11].

D. Riesgos de un despliegue irresponsable

Reportar la exactitud (0.866) sin contexto sugeriría un modelo excelente cuando, en el umbral por defecto, los *ensembles* de árboles omiten el 84–92% de los casos verdaderos. Desplegar tal modelo como clasificador binario sería activamente perjudicial. La deriva de calibración entre poblaciones, el error de etiquetado por autorreporte y los sesgos de cobertura demográfica de la encuesta implican que cualquier despliegue debe recalibrarse localmente y monitorearse continuamente, y debe presentar la incertidumbre con honestidad [17], [19].

E. Implicaciones prácticas para el cribado poblacional

¿Por qué es útil un AUC de ≈ 0.83 ? Una discriminación de esta magnitud es modesta para un diagnóstico individual pero valiosa para el *triaje poblacional*. La estratificación calibrada concentra el riesgo: la banda Muy Alto ($\approx 10\%$ de la población) acumula 48% de prevalencia observada—un enriquecimiento de $3.4\times$ sobre la tasa base del 13.9%—por lo que cribar primero ese subgrupo eleva notablemente el rendimiento de las pruebas confirmatorias bajo un presupuesto fijo. De forma equivalente, el punto de operación orientado a la exclusión conserva $\approx 89\%$ de sensibilidad mientras retira del estudio inmediato a los encuestados de menor riesgo.

¿Por qué no es un diagnóstico? El modelo estima la probabilidad de diabetes *autorreportada* y *previamente diagnosticada* a partir de indicadores no bioquímicos; no mide la glucemia ni establece la enfermedad, y su valor predictivo positivo en el umbral más estricto es solo 0.48. El diagnóstico requiere confirmación bioquímica según los estándares clínicos [33]; el puntaje es, a lo sumo, una indicación para realizar pruebas.

¿Cómo podría apoyar la salud pública? Como pre-cribado barato basado solo en cuestionario, puede priorizar la difusión, asignar pruebas limitadas de HbA1c/glucosa y señalar individuos para programas de estilo de vida—usos que toleran una discriminación imperfecta porque el costo de un falso positivo (una prueba ofrecida) es bajo y el de un falso negativo se mitiga con la atención de rutina. Trabajos recientes que combinan tales modelos con explicaciones apuntan en la misma dirección [34].

Riesgos de mal uso. Tratar el puntaje como un diagnóstico, desplegarlo en el umbral por defecto 0.5 (que omite la mayoría de los casos), transportarlo sin recalibración o permitir que la señal de ingreso/acceso racione la atención serían todos perjudiciales. Las herramientas de cribado deben gobernarse, monitorearse y nunca sustituir el juicio clínico.

VII. LECCIONES APRENDIDAS PARA EL ML CLÍNICO

La fuga de información lo decide todo (H4). BRFSS carece de laboratorios diagnósticos, por lo que nuestro *benchmark* es honesto por construcción. Si se hubieran incluido la hemoglobina glicosilada o la glucosa en ayunas como predictores—como es común en el ML de diabetes—el modelo esencialmente reaprendería el umbral diagnóstico, inflando el ROC-AUC hacia ≈ 0.98 . Tales números miden tautología, no capacidad de cribado [8], [9]. El contraste es cuantitativo y contundente: admitir biomarcadores diagnósticos cambia la discriminación en $\Delta\text{AUC} \approx 0.15$, mientras que cambiar del estimador más simple al mejor la cambia en $\Delta\text{AUC} \approx 0.007$. Una decisión de gobernanza de datos mueve el desempeño unas veinte veces más que todo el esfuerzo de selección de modelo. La decisión de modelado más consecuente es, por tanto, la política de *admisibilidad de variables*, no la elección del estimador—una lección que estándares de reporte como TRIPOD+AI [35] están diseñados para hacer cumplir.

Reproducibilidad. Una semilla fija, una única partición compartida, transformadores ajustados dentro de los pliegues y

la disponibilidad pública de cada métrica, figura y umbral son lo que hace confiable la comparación. Las tuberías propensas a fuga o subespecificadas son una causa primaria de ML clínico irreproducible [9].

Calibración sobre exactitud. Para uso clínico, la probabilidad debe ser confiable [12], [13]. Encontramos la calibración ($ECE \leq 0.004$) más decisiva para la banda de riesgo posterior que las diferencias sub-porcentuales de AUC entre modelos.

Interpretabilidad como evidencia de primer orden. El acuerdo entre SHAP e importancia por permutación, y la recuperación de epidemiología de manual, dan a los clínicos una razón para *confiar* en el modelo. Donde un modelo simple y auditable iguala a uno complejo, debe preferirse el simple [17], [18].

Los conjuntos públicos arrastran sesgos. El autorreporte, la no respuesta y los sesgos de cobertura, más el ruido de etiqueta por casos no diagnosticados, acotan el desempeño alcanzable y pueden codificar disparidades sociales (p. ej. el efecto del ingreso). El desempeño estadístico y la utilidad clínica *no* son la misma cantidad [10], [11].

VIII. LIMITACIONES Y AMENAZAS A LA VALIDEZ

Enunciamos las limitaciones explícitamente, pues su efecto acumulado acota toda afirmación anterior.

Diseño observacional y transversal. BRFSS es una encuesta de un solo momento, no un cohorte. Soporta *asociación*, no *causalidad*: las atribuciones SHAP y las razones de momios describen cómo covarían las variables con la etiqueta bajo el modelo, no efectos causales. Algunas asociaciones son plausiblemente susceptibles de causalidad inversa —por ejemplo, una mala salud autopercebida (*GenHlth*) o la dificultad para caminar pueden ser en parte *consecuencias* de la diabetes más que precursoras—por lo que los órdenes no deben leerse como palancas causales accionables.

Autorreporte y ruido de etiqueta. Tanto las predictoras como el desenlace son autorreportados por teléfono, lo que invita al sesgo de memoria y de deseabilidad social. De forma crucial, el desenlace es diabetes *previamente diagnosticada*; la fracción sustancial de casos *no diagnosticados* se etiqueta erróneamente como negativa, atenuando las asociaciones medidas y probablemente *subestimando* la señal alcanzable.

Sesgo de selección y cobertura. El muestreo telefónico subrepresenta a los grupos sin acceso telefónico estable y a los no respondedores, y el ponderado post-estratificación (no usado aquí) solo corrige esto parcialmente. El gradiente socioeconómico observado puede por tanto codificar disparidades de acceso más que biología, con implicaciones de equidad para el despliegue.

Variables faltantes. No hay biomarcadores (HbA1c, glucosa en ayunas, lípidos), ni detalle genético o de antecedentes familiares más allá de ítems toscos, ni medicación, y solo proxies burdos de dieta/actividad. La meseta que observamos es condicional a este espacio de variables empobrecido; entradas más ricas probablemente la elevarían.

Generalización. Los resultados corresponden a adultos de EE. UU. encuestados en 2015. El transporte geográfico (p.

ej. a otros sistemas de salud o a la población mexicana) y el temporal (deriva poblacional desde 2015) requieren ambos validación externa y recalibración antes de cualquier uso [11], [35].

Filas duplicadas que cruzan la partición. Como el 9.5% de las filas son duplicados exactos y la partición es aleatoria, vectores de respuesta idénticos pueden aparecer en entrenamiento y prueba, lo que puede inflar ligeramente la discriminación *absoluta*. Esto afecta a todos los modelos por igual y por tanto no altera la conclusión *comparativa* que es la afirmación central del artículo.

Salvedades metodológicas. SVM y KNN se ajustaron sobre submuestras por tratabilidad, lo que puede subestimar modestamente su desempeño—aunque ambos quedan rezagados por márgenes mucho mayores que cualquier efecto de ajuste plausible. Las métricas dependientes de umbral usan el corte 0.5; lo mitigamos ordenando por ROC/PR-AUC y con el análisis explícito de estratificación. Reportamos una sola partición con *IC bootstrap*; pruebas complementarias con validación cruzada y múltiples semillas [32] quedan como trabajo futuro.

IX. TRABAJO FUTURO

Varias direcciones se siguen de forma natural. (1) *Estratificación de riesgo clínico explicable*: extender la banda calibrada con justificaciones SHAP por paciente. (2) *Modelado longitudinal de pacientes*: pasar de instantáneas transversales a trayectorias, modelando cómo evoluciona el riesgo individual en el tiempo. (3) *Evolución temporal del riesgo*: detectar mejoría/deterioro y señales de alerta temprana a partir de mediciones repetidas. (4) *Soporte a la decisión clínica*: combinar riesgo, evolución y reglas auditables en recomendaciones priorizadas y justificadas. (5) *Integración con plataformas clínicas digitales*: un motor calibrado e interpretable de este tipo podría incorporarse como módulo de soporte a la decisión en un sistema de información clínica como la plataforma PRE-DIA, estrictamente como entorno de implementación futura y nunca como sustituto del juicio clínico.

X. CONCLUSIONES

Comparamos nueve estimadores de ML para la predicción del riesgo de diabetes sobre una gran encuesta poblacional libre de fuga (BRFSS 2015), con intervalos de confianza *bootstrap* sobre un conjunto de prueba retenido. Se siguen cinco conclusiones. *Primera*, la información disponible limita el desempeño más que el algoritmo: nueve modelos de capacidad muy distinta se saturan en ROC-AUC ≈ 0.83 , una meseta fijada por entradas toscas y autorreportadas, no por ningún estimador. *Segunda*, los modelos complejos ofrecen solo una mejora marginal—el mejor modelo supera a la regresión logística por $\Delta AUC = 0.007$ (*IC bootstrap* [0.006, 0.009]), estadísticamente resoluble a este tamaño muestral pero prácticamente despreciable, mientras que los principales modelos no lineales son mutuamente indistinguibles; la exactitud reportada (0.866) apenas supera la base mayoritaria de 0.861. *Tercera*, la interpretabilidad es clínicamente valiosa: SHAP e importancia por

permutación coinciden y recuperan epidemiología establecida, favoreciendo modelos transparentes donde igualan a los complejos. *Cuarta*, controlar la fuga de información es esencial y dominante: admitir biomarcadores diagnósticos modificaría el AUC en ≈ 0.15 , unas veinte veces la brecha entre el mejor y el más simple, por lo que la gobernanza de admisibilidad de variables es la decisión decisiva. *Quinta*, estos modelos apoyan el *cribado*, *no el diagnóstico*: la salida accionable es una probabilidad calibrada (ECE isotónico = 0.003) y su mapeo a bandas de riesgo que separan la prevalencia observada 16 veces en datos retenidos, útil para el triaje pero inadecuada como etiqueta diagnóstica y que requiere recalibración local y monitoreo. En suma, para la predicción de diabetes a partir de indicadores de salud poblacional, el rigor, la calibración, la interpretabilidad y la reproducibilidad aportan más valor que la búsqueda de exactitud marginal.

DECLARACIÓN DE REPRODUCIBILIDAD

Todos los experimentos usan una semilla aleatoria fija y una única partición estratificada compartida 60/20/20 (entrenamiento/validación/prueba); toda métrica reportada se calcula sobre el conjunto de prueba retenido, nunca usado para selección de modelos ni calibración. Los datos son la extracción pública *Diabetes Health Indicators* [23] de la encuesta CDC BRFSS 2015 [24]; no se usaron datos privados. La tubería completa (auditoría de datos, entrenamiento, calibración, estratificación de riesgo, explicabilidad y validación clínica), junto con cada tabla de métricas y figura aquí reproducidas, está disponible como *notebooks* y *scripts* ejecutables en el repositorio de investigación del proyecto, implementada con scikit-learn [25] y las bibliotecas de modelos públicamente documentadas citadas en la Sección IV.

REFERENCIAS

- [1] International Diabetes Federation, "IDF diabetes atlas, 10th ed." International Diabetes Federation, Brussels, Belgium, Tech. Rep., 2021.
- [2] American Diabetes Association, "Classification and diagnosis of diabetes: Standards of medical care in diabetes—2021," *Diabetes Care*, vol. 44, no. Supplement 1, pp. S15–S33, 2021, doi: 10.2337/dc21-S002
- [3] Z. Xie, O. Nikolayeva, J. Luo, and D. Li, "Building risk prediction models for type 2 diabetes using machine learning techniques," *Preventing Chronic Disease*, vol. 16, p. E130, 2019, doi: 10.5888/pcd16.190109
- [4] A. Dinh, S. Miertschin, A. Young, and S. D. Mohanty, "A data-driven approach to predicting diabetes and cardiovascular disease with machine learning," *BMC Medical Informatics and Decision Making*, vol. 19, no. 1, p. 211, 2019, doi: 10.1186/s12911-019-0918-5
- [5] N. P. Tigga and S. Garg, "Prediction of type 2 diabetes using machine learning classification methods," *Procedia Computer Science*, vol. 167, pp. 706–716, 2020, doi: 10.1016/j.procs.2020.03.336
- [6] A. Rashid, "Diabetes dataset," Mendeley Data, V1, 2020, doi: 10.17632/wj9rwkp9c2.1
- [7] E. Christodoulou, J. Ma, G. S. Collins, E. W. Steyerberg, J. Y. Verbakel, and B. Van Calster, "A systematic review shows no performance benefit of machine learning over logistic regression for clinical prediction models," *Journal of Clinical Epidemiology*, vol. 110, pp. 12–22, 2019, doi: 10.1016/j.jclinepi.2019.02.004
- [8] S. Kaufman, S. Rosset, C. Perlich, and O. Stitelman, "Leakage in data mining: Formulation, detection, and avoidance," *ACM Transactions on Knowledge Discovery from Data (TKDD)*, vol. 6, no. 4, pp. 1–21, 2012, doi: 10.1145/2382577.2382579
- [9] S. Kapoor and A. Narayanan, "Leakage and the reproducibility crisis in machine-learning-based science," *Patterns*, vol. 4, no. 9, p. 100804, 2023, doi: 10.1016/j.patter.2023.100804

- [10] E. W. Steyerberg, *Clinical Prediction Models: A Practical Approach to Development, Validation, and Updating*, 2nd ed., ser. Statistics for Biology and Health. Cham, Switzerland: Springer, 2019, doi: 10.1007/978-3-030-16399-0
- [11] B. Van Calster, D. J. McLernon, M. van Smeden, L. Wynants, and E. W. Steyerberg, "Calibration: The Achilles heel of predictive analytics," *BMC Medicine*, vol. 17, no. 1, p. 230, 2019, doi: 10.1186/s12916-019-1466-7
- [12] A. Niculescu-Mizil and R. Caruana, "Predicting good probabilities with supervised learning," in *Proc. 22nd Int. Conf. on Machine Learning (ICML)*, 2005, pp. 625–632, doi: 10.1145/1102351.1102430
- [13] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On calibration of modern neural networks," in *Proc. 34th Int. Conf. on Machine Learning (ICML)*, ser. PMLR, vol. 70, 2017, pp. 1321–1330.
- [14] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017, pp. 4765–4774.
- [15] S. M. Lundberg, G. Erion, H. Chen, A. DeGrave, J. M. Prutkin, B. Nair, R. Katz, J. Himmelfarb, N. Bansal, and S.-I. Lee, "From local explanations to global understanding with explainable AI for trees," *Nature Machine Intelligence*, vol. 2, no. 1, pp. 56–67, 2020, doi: 10.1038/s42256-019-0138-9
- [16] M. T. Ribeiro, S. Singh, and C. Guestrin, "“why should I trust you?”: Explaining the predictions of any classifier," in *Proc. 22nd ACM SIGKDD Int. Conf. on Knowledge Discovery and Data Mining*, 2016, pp. 1135–1144, doi: 10.1145/2939672.2939778
- [17] C. Rudin, "Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead," *Nature Machine Intelligence*, vol. 1, no. 5, pp. 206–215, 2019, doi: 10.1038/s42256-019-0048-x
- [18] R. Caruana, Y. Lou, J. Gehrke, P. Koch, M. Sturm, and N. Elhadad, "Intelligible models for healthcare: Predicting pneumonia risk and hospital 30-day readmission," in *Proc. 21st ACM SIGKDD Int. Conf. on Knowledge Discovery and Data Mining*, 2015, pp. 1721–1730, doi: 10.1145/2783258.2788613
- [19] M. Ghassemi, L. Oakden-Rayner, and A. L. Beam, "The false hope of current approaches to explainable artificial intelligence in health care," *The Lancet Digital Health*, vol. 3, no. 11, pp. e745–e750, 2021, doi: 10.1016/S2589-7500(21)00208-9
- [20] T. Saito and M. Rehmsmeier, "The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets," *PLoS ONE*, vol. 10, no. 3, p. e0118432, 2015, doi: 10.1371/journal.pone.0118432
- [21] H. He and E. A. Garcia, "Learning from imbalanced data," *IEEE Transactions on Knowledge and Data Engineering*, vol. 21, no. 9, pp. 1263–1284, 2009, doi: 10.1109/TKDE.2008.239
- [22] D. Chicco and G. Jurman, "The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation," *BMC Genomics*, vol. 21, no. 1, p. 6, 2020, doi: 10.1186/s12864-019-6413-7
- [23] A. Teboul, "Diabetes health indicators dataset," Kaggle, 2021, derived from the CDC Behavioral Risk Factor Surveillance System (BRFSS) 2015. [Online]. Available: <https://www.kaggle.com/datasets/alextteboul/diabetes-health-indicators-dataset>
- [24] Centers for Disease Control and Prevention, "Behavioral risk factor surveillance system (brfss) 2015 survey data and documentation," U.S. Department of Health and Human Services, CDC, Tech. Rep., 2015.
- [25] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and É. Duchesnay, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [26] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324
- [27] J. H. Friedman, "Greedy function approximation: A gradient boosting machine," *Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001, doi: 10.1214/aos/1013203451
- [28] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proc. 22nd ACM SIGKDD Int. Conf. on Knowledge Discovery and Data Mining (KDD)*, 2016, pp. 785–794, doi: 10.1145/2939672.2939785
- [29] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "LightGBM: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017, pp. 3146–3154.

- [30] T. Cover and P. Hart, "Nearest neighbor pattern classification," *IEEE Transactions on Information Theory*, vol. 13, no. 1, pp. 21–27, 1967, doi: 10.1109/TIT.1967.1053964
- [31] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995, doi: 10.1007/BF00994018
- [32] J. Demšar, "Statistical comparisons of classifiers over multiple data sets," *Journal of Machine Learning Research*, vol. 7, pp. 1–30, 2006.
- [33] N. A. ElSayed *et al.*, "2. classification and diagnosis of diabetes: Standards of care in diabetes—2023," *Diabetes Care*, vol. 46, no. Supplement 1, pp. S19–S40, 2023, doi: 10.2337/dc23-S002
- [34] I. Tasin, T. U. Nabil, S. Islam, and R. Khan, "Diabetes prediction using machine learning and explainable AI techniques," *Healthcare Technology Letters*, vol. 10, no. 1-2, pp. 1–10, 2023, doi: 10.1049/htl2.12039
- [35] G. S. Collins *et al.*, "TRIPOD+AI statement: Updated guidance for reporting clinical prediction models that use regression or machine learning methods," *BMJ*, vol. 385, p. e078378, 2024, doi: 10.1136/bmj-2023-078378