

Auditoría y Revalidación de un Sistema de Predicción de Diabetes Basado en Aprendizaje Automático: Un Estudio de Caso sobre Fuga de Información y Despliegue Clínico

Guillermo Álvarez Sánchez, Gabriel Iván Villafuerte Armenta,
Cristopher Yanhyu Muñoz Prado, Arianna Valentina Giannoccaro Quiñonez

Resumen—Los sistemas de aprendizaje automático se integran cada vez más en el software clínico, pero su desempeño reportado suele aceptarse sin escrutinio metodológico. Presentamos la auditoría del módulo de predicción de diabetes de PREDIA, una plataforma de expediente clínico electrónico en producción cuyo modelo anunciaba una exactitud del 97.89%. Trabajando exclusivamente con los propios artefactos del proyecto, mostramos que esa cifra no es reproducible ni honesta: el estimador desplegado es una regresión logística codificada directamente en TypeScript, entrenada sobre un conjunto distinto de 947 muestras cuyas variables (urea, creatinina, VLDL) están ausentes del corpus de 100,000 filas de la plataforma, y su exactitud está inflada por fuga de información a través de la HbA1c, un criterio diagnóstico oficial de diabetes. Una sonda validada por 5-fold confirma que la HbA1c por sí sola alcanza 0.93 de ROC-AUC, mientras que un modelo de *cribado* libre de fuga llega solo a ≈ 0.66 . Reentrenamos y comparamos nueve clasificadores bajo un protocolo con control de fuga, validación cruzada estratificada y un panel de métricas de orientación clínica; la regresión logística es el mejor modelo honesto (ROC-AUC 0.659, MCC 0.223). Lo interpretamos con importancia por permutación y SHAP, y lo migramos a la API REST de PREDIA como un modelo TypeScript autocontenido con un contrato de variables rediseñado y libre de fuga. El estudio aporta una metodología de auditoría reproducible y un relato honesto de la brecha entre métricas infladas y métricas honestas en el aprendizaje automático clínico.

Palabras clave—fuga de información, predicción de diabetes, auditoría de modelos, reproducibilidad, apoyo a la decisión clínica, interpretabilidad, aprendizaje automático

I. INTRODUCCIÓN

La diabetes mellitus es una de las principales cargas de salud pública a nivel mundial, afectando a unos 537 millones de adultos [1]. Dado que la identificación temprana de individuos en riesgo permite intervenciones preventivas, el aprendizaje automático (AA) se ha propuesto ampliamente para la estratificación del riesgo de diabetes. Sin embargo, el valor clínico de tales modelos depende por completo de la validez de su desempeño reportado. Cuando un modelo se evalúa incorrectamente—lo más común, mediante fuga de información (data leakage), el uso inadvertido de información no disponible al momento de la predicción o que codifica el desenlace—las métricas reportadas se inflan severamente y el sistema falla de forma silenciosa en producción [2], [3].

Este artículo es un estudio de caso de exactamente ese tipo de fallo, descubierto al auditar PREDIA, una plataforma de expediente clínico electrónico (ECE) en producción. PREDIA distribuía un módulo de predicción de diabetes que anunciaba una exactitud del 97.89%. En lugar de aceptar esa cifra, sometimos el modelo y sus datos a una auditoría reproducible usando únicamente los artefactos del propio proyecto.

Objetivos. (i) Determinar si la exactitud reportada por PREDIA es válida y reproducible; (ii) probar la existencia de fuga de información y fallos metodológicos; (iii) establecer una línea base honesta de desempeño reentrenando y comparando múltiples clasificadores bajo un protocolo con control de fuga; y (iv) desplegar el modelo seleccionado de vuelta en PREDIA sin romper la plataforma.

Contribuciones. (1) Una auditoría formal y reproducible que demuestra que la exactitud del modelo desplegado es a la vez irreproducible (entrenado en un conjunto distinto con variables ausentes) e inflada por la fuga de la HbA1c. (2) Un *benchmark* con control de fuga de nueve clasificadores, separando un marco honesto de *cribado* de un marco *clínico* que cuantifica la contribución de la fuga (+0.285 de ROC-AUC). (3) Interpretabilidad y análisis clínico del modelo honesto. (4) Una migración a producción del modelo revalidado hacia la API REST de PREDIA con un contrato de variables rediseñado y libre de fuga.

II. TRABAJOS RELACIONADOS

Los aprendices basados en árboles y en kernels dominan la predicción clínica tabular: bosques aleatorios [4], árboles potenciados por gradiente como los de XGBoost [5] y LightGBM [6], máquinas de soporte vectorial [7] y clasificadores por vecinos más cercanos [8]. Todos los experimentos aquí emplean el ecosistema `scikit-learn` [9]. Para la interpretabilidad del modelo adoptamos los valores SHAP [10] junto con la importancia por permutación [4].

La fuga de información es una amenaza reconocida desde hace tiempo pero persistente para la validez de los estudios de AA [2]; trabajos recientes la documentan como un motor primario de la crisis de reproducibilidad en la ciencia basada en AA en múltiples disciplinas [3]. En contextos clínicos, la fuga surge con frecuencia al incluir mediciones diagnósticas

TABLE I
CARACTERÍSTICAS DEL CORPUS DIABETES_DATASET.CSV

Propiedad	Valor
Instancias	100,000
Columnas totales	31
Atributos numéricos	24 (incl. objetivo)
Atributos categóricos	7
Variable objetivo	diagnosed_diabetes
Clase positiva (Diabetes)	59,998 (60.0%)
Clase negativa (No Diabetes)	40,002 (40.0%)
Razón de desbalance	1.50
Valores faltantes	0
Filas duplicadas	0
Partición train/test	80,000 / 20,000 (estratificada)

que *definen* la etiqueta. El diagnóstico de diabetes se rige por umbrales de laboratorio—siendo la HbA1c $\geq 6.5\%$ un criterio primario [11]—de modo que cualquier modelo que consuma HbA1c para predecir una etiqueta derivada de la HbA1c está, por construcción, filtrando información. Como la exactitud es engañosa bajo desbalance de clases, reportamos el coeficiente de correlación de Matthews (MCC), más informativo para la clasificación binaria [12]. Finalmente, el modelo original de PREDIA fue entrenado sobre un pequeño conjunto público de diabetes [13] cuyo conjunto de variables difiere de los datos operativos de la plataforma—una discrepancia central en nuestros hallazgos.

III. METODOLOGÍA

A. Conjunto de datos

Todos los experimentos usan `diabetes_dataset.csv`, el corpus distribuido con el repositorio de PREDIA (Tabla I). Contiene 100,000 instancias y 31 atributos que describen demografía, situación socioeconómica, estilo de vida, antropometría, signos vitales, perfil lipídico y mediciones de laboratorio. El objetivo binario `diagnosed_diabetes` presenta un desbalance leve (60.0% positivo / 40.0% negativo, razón 1.50). El corpus no tiene valores faltantes ni filas duplicadas.

B. Taxonomía de variables con control de fuga

La decisión metodológica definitoria de este estudio es una taxonomía explícita de variables que controla la fuga:

- **Fuga directa (siempre eliminadas):** `diabetes_stage` (la categoría diagnóstica en sí) y `diabetes_risk_score` (un proxy de riesgo derivado).
- **Laboratorios diagnósticos:** `hba1c`, `glucose_fasting`, `glucose_postprandial` e `insulin_level`. Por ser criterios diagnósticos, se *excluyen* del marco honesto de *cribado* y se *incluyen* solo en un marco *clínico* usado para cuantificar su contribución (con fuga).
- **Variables de cribado:** demografía, situación socioeconómica, estilo de vida, antecedentes familiares,




Fig. 1. Correlación de Pearson absoluta con el objetivo. Las señales más fuertes (rojo) son variables diagnósticas/con fuga (`hba1c`, `glucose_*`, `diabetes_risk_score`); las variables legítimas de cribado (azul) están débilmente correlacionadas.

antropometría, signos vitales y perfil lipídico—las 24 entradas que una herramienta de riesgo pre-diagnóstica puede recolectar legítimamente.

La Fig. 1 confirma que las variables más correlacionadas con el objetivo son precisamente los laboratorios diagnósticos, lo que motiva esta separación.

C. Preprocesamiento, validación y pipeline

Los atributos categóricos se codifican con one-hot y los numéricos se estandarizan (z -score); los binarios se mantienen. Todas las transformaciones se ajustan *dentro* de un Pipeline de `scikit-learn` [9] para evitar la contaminación train/test. Usamos una partición estratificada 80/20 y validación cruzada estratificada de 4 particiones para la selección de modelos, con una semilla global de 42 para reproducibilidad total. La Fig. 2 resume el protocolo de extremo a extremo.

IV. AUDITORÍA DEL MODELO ORIGINAL

A. Arquitectura y desempeño reportado

La inspección del artefacto serializado (`modelo_diabetes.pkl`) muestra que el estimador desplegado es una *regresión logística* con 11 variables de entrada (`Gender`, `AGE`, `Urea`, `Cr`, `HbA1c`, `Chol`, `TG`, `HDL`, `LDL`, `VLDL`, `BMI`), un único intercepto de 7.578, entrenada con 947 muestras (757 train / 190 test). Los metadatos de la plataforma y la semilla de la base de datos reportan una exactitud de 0.9789, mientras que la documentación en el código afirma simultáneamente 98.42% de exactitud, 100% de precisión y 0.9975 de AUC—una inconsistencia interna que ya socava la confianza.

B. Reproducibilidad y discrepancia de datos/variables

No existe código de entrenamiento ni notebook en el repositorio; la metodología, por tanto, no es reproducible. Además, el modelo desplegado fue entrenado sobre un corpus distinto (el conjunto público de 947 muestras [13]): tres de sus once variables—`Urea`, `Cr` y `VLDL`—están *ausentes* del




Fig. 2. Pipeline reproducible de auditoría a despliegue.

conjunto operativo de PREDIA, y las variables lipídicas usan una escala de unidades incompatible. El modelo no puede evaluarse tal cual sobre los propios datos de la plataforma. Observamos además que, en tiempo de servicio, el modelo no se carga desde el archivo `.pkl`, sino que se reimplementa como coeficientes codificados directamente en TypeScript, aumentados con reglas clínicas escritas a mano.

C. Fuga de información

La HbA1c es la segunda variable más importante del modelo original, pero $HbA1c \geq 6.5\%$ es el criterio diagnóstico de diabetes [11]. Usarla como predictor, por tanto, filtra la etiqueta. La Tabla II cuantifica esto con regresiones logísticas validadas por 5-fold sobre subconjuntos aislados de variables: la HbA1c por sí sola ya produce 0.93 de ROC-AUC, el par de puros proxies `diabetes_stage+risk_score` alcanza 0.997, mientras que un subconjunto de cribado libre de fuga llega solo a 0.61. La exactitud reportada de $\approx 98\%$ es, así, solo alcanzable con variables diagnósticas/con fuga; refleja fuga, no capacidad predictiva pre-diagnóstica.

TABLE II
DEMOSTRACIÓN DE FUGA: REGRESIÓN LOGÍSTICA VALIDADA POR 5-FOLD ENTRENADA SOBRE SUBCONJUNTOS AISLADOS DE VARIABLES DE `DIABETES_DATASET.CSV`

Subconjunto de variables	Exactitud	ROC-AUC
<code>hba1c</code> solamente	0.8520	0.9325
<code>glucose_fasting</code> solamente	0.7307	0.8082
Labs. diagnósticos (<code>HbA1c+glucosa+insulina</code>)	0.8567	0.9337
<code>diabetes_stage+risk_score</code>	0.9979	0.9974
Cribado (numéricas no diagnósticas)	0.6163	0.6121

V. EXPERIMENTACIÓN

Reentrenamos nueve clasificadores bajo el marco de cribado: regresión logística, bosque aleatorio [4], extra trees, gradient boosting por histograma, XGBoost [5], LightGBM [6], máquina de soporte vectorial (kernel RBF) [7], k vecinos más cercanos [8] y un perceptrón multicapa. Cada estimador se envuelve en el pipeline común de preprocesamiento y se ajusta con `RandomizedSearchCV` (8 candidatos, 4-fold estratificado, métrica ROC-AUC). Dado que el SVM con kernel y el KNN escalan mal a 8×10^4 filas de entrenamiento, se ajustan sobre una submuestra estratificada de 8,000 filas y se evalúan sobre el conjunto de test completo; esto se reporta explícitamente. Todas las ejecuciones comparten `random_state=42`.

VI. RESULTADOS

La Tabla III reporta el desempeño en test de los nueve modelos bajo el marco honesto de cribado. Destacan tres hallazgos. Primero, el problema honesto es genuinamente difícil: todos los modelos se agrupan alrededor de ROC-AUC 0.65–0.66. Segundo, *la regresión logística es el mejor modelo honesto* por ROC-AUC (0.6591) y por MCC (0.2229), y es también el mejor calibrado y más equilibrado. Tercero, los ensambles de árboles y el SVM cambian especificidad por sensibilidad (p. ej. el SVM alcanza 0.96 de sensibilidad pero 0.09 de especificidad), lo que infla la F1 sin mejorar la discriminación. Los resúmenes comparativos de ROC y ROC-AUC se muestran en las Figs. 3 y 4; la matriz de confusión y el diagrama de fiabilidad del modelo seleccionado aparecen en las Figs. 5 y 6.

Para cuantificar la contribución de la fuga de forma directa, la Tabla IV contrasta el marco de cribado con un marco clínico que reintroduce los laboratorios diagnósticos. Añadir esas variables eleva la ROC-AUC de ≈ 0.66 a ≈ 0.94 —un aumento medio de $+0.285$ —lo que confirma que la aparente excelencia del sistema original era casi enteramente fuga.

VII. INTERPRETABILIDAD

Interpretamos el modelo seleccionado con importancia por permutación (caída en la ROC-AUC de test) y valores SHAP [10]. Ambos métodos coinciden de cerca (Tabla V, Figs. 7 y 8): `family_history_diabetes`, `age`

TABLE III

DESEMPEÑO EN TEST DE NUEVE CLASIFICADORES BAJO EL MARCO HONESTO DE *cribado* (SIN VARIABLES DE LABORATORIO DIAGNÓSTICAS). MODELOS ORDENADOS POR ROC-AUC. MEJOR VALOR POR COLUMNA EN NEGRITA. † AJUSTADO SOBRE UNA SUBMUESTRA ESTRATIFICADA DE 8,000 FILAS.

Modelo	Exa.	Exa. Bal.	Prec.	Sens.	Espec.	F1	ROC-AUC	MCC	CV-AUC
Regresión Logística	0.6044	0.6136	0.7144	0.5675	0.6597	0.6325	0.6591	0.2229	0.6610
Gradient Boosting (Hist.)	0.6310	0.5790	0.6489	0.8391	0.3189	0.7318	0.6579	0.1856	0.6591
XGBoost	0.6289	0.5781	0.6488	0.8317	0.3246	0.7289	0.6573	0.1817	0.6587
LightGBM	0.6280	0.5753	0.6464	0.8387	0.3119	0.7301	0.6558	0.1776	0.6574
Random Forest	0.6244	0.5594	0.6340	0.8848	0.2340	0.7387	0.6549	0.1576	0.6573
Extra Trees	0.6194	0.5438	0.6237	0.9220	0.1656	0.7441	0.6538	0.1356	0.6551
MLP (Red Neuronal)	0.6244	0.5821	0.6541	0.7937	0.3704	0.7172	0.6530	0.1807	0.6555
SVM (RBF)†	0.6123	0.5254	0.6130	0.9600	0.0907	0.7482	0.6328	0.1044	0.6360
KNN†	0.6003	0.5441	0.6268	0.8251	0.2631	0.7124	0.5845	0.1061	0.5872




Fig. 3. Curvas ROC comparativas de los nueve clasificadores (marco de cribado).

TABLE IV

EFFECTO DE INCLUIR VARIABLES DE LABORATORIO DIAGNÓSTICAS: MARCO HONESTO DE *cribado* VS. MARCO *clínico* (CON HBA1C, GLUCOSA E INSULINA). LA BRECHA DE ROC-AUC CUANTIFICA LA CONTRIBUCIÓN DE LA FUGA DE INFORMACIÓN.

Modelo	Cribado		Clínico	
	Exa.	ROC-AUC	Exa.	ROC-AUC
Regresión Logística	0.6044	0.6591	0.8878	0.9339
Random Forest	0.6244	0.6549	0.9196	0.9417
XGBoost	0.6289	0.6573	0.9199	0.9444
Media Δ ROC-AUC	+0.285 (contribución de la fuga)			

y `physical_activity_minutes_per_week` dominan, seguidas de `bmi` y `diet_score`.

Impacto clínico. De forma tranquilizadora, los predictores dominantes son *modificables o registrables de forma rutinaria*




Fig. 4. ROC-AUC por modelo (marco de cribado).




Fig. 5. Matriz de confusión del modelo de cribado de regresión logística seleccionado sobre el conjunto de test de 20,000 instancias.

sin pruebas de laboratorio (antecedentes familiares, actividad física, índice de masa corporal, dieta), que es exactamente en lo que una herramienta de cribado pre-diagnóstico debería apoyarse. **Riesgos de interpretación.** La importancia no implica causalidad; las asociaciones son observacionales, el corpus es de procedencia desconocida y los tamaños de efecto




Fig. 6. Diagrama de fiabilidad (calibración) del modelo seleccionado.

TABLE V
VARIABLES MÁS INFLUYENTES DEL MODELO DE CRIBADO
SELECCIONADO, POR IMPORTANCIA DE PERMUTACIÓN (CAÍDA EN
ROC-AUC) Y POR VALOR SHAP ABSOLUTO MEDIO.

Importancia por permutación		SHAP ($ \phi $ medio)	
Variable	ΔAUC	Variable	$ \phi $
family_history_diabetes	0.0816	age	0.0539
age	0.0340	family_history_diabetes	0.0536
physical_activity	0.0179	physical_activity	0.0362
bmi	0.0037	bmi	0.0220
diet_score	0.0023	diet_score	0.0126
hdl_cholesterol	0.0013	hdl_cholesterol	0.0125
screen_time	0.0012	triglycerides	0.0082
triglycerides	0.0008	screen_time	0.0076




Fig. 7. Importancia por permutación del modelo de cribado seleccionado.

modestos implican que las predicciones individuales conllevan una incertidumbre sustancial.




Fig. 8. Resumen SHAP (beeswarm) del modelo de cribado seleccionado.

VIII. DISCUSIÓN

Por qué el modelo original parecía excelente. Su exactitud de $\approx 98\%$ fue el producto conjunto de dos artefactos: la evaluación sobre un conjunto de datos distinto y más pequeño, y la fuga de información a través de la HbA1c. Ninguno refleja la capacidad del modelo para anticipar la diabetes antes del diagnóstico. **Métricas infladas vs. honestas.** El mismo algoritmo (regresión logística) pasa de ROC-AUC 0.93 (con fuga) a 0.66 (libre de fuga); la exactitud bajo desbalance es especialmente engañosa aquí, razón por la cual enfatizamos el MCC y la exactitud balanceada [12]. **Implicaciones clínicas.** Una señal pre-diagnóstica honesta de ROC-AUC ≈ 0.66 es modesta; el modelo solo es defendible como *apoyo* a la decisión y nunca debe presentarse como un diagnóstico. **Limitaciones del conjunto de datos.** El corpus tiene apariencia sintética, procedencia no documentada, carece de validez externa y agrupa variables que definen el diagnóstico, lo que vuelve peligroso el modelado ingenuo. **Riesgos de despliegue.** Distribuir un modelo inflado por fuga invita al sesgo de automatización y a una confianza clínica insegura; esto motivó tanto la revalidación como el contrato de variables rediseñado.

IX. INTEGRACIÓN EN PRODUCCIÓN

El modelo revalidado se integró en PREDIA preservando las restricciones de la plataforma. (i) **Decisión de arquitectura:** el runtime de servicio es TypeScript puro (sin proceso auxiliar de Python), elegido por portabilidad; por ello exportamos el modelo de cribado de regresión logística—que es además el

mejor modelo honesto—como coeficientes simples más los parámetros de one-hot/escalado, consumidos genéricamente en inferencia. (ii) **Exportación:** el pipeline completo de `scikit-learn` se serializa (`joblib/pickle`) para reproducibilidad, y se genera un archivo JSON de parámetros para el runtime de TypeScript. (iii) **API REST:** el endpoint `/api/predicciones/nueva` y su esquema de validación se migraron al nuevo contrato de 24 variables libre de fuga; el formulario web de predicción se reescribió en consecuencia. (iv) **Compatibilidad:** las *lecturas* de predicciones (p. ej. la aplicación móvil) no se vieron afectadas, ya que solo cambió la *creación* de predicciones; los metadatos del modelo se corrigieron del inflado 97.89% al valor honesto. Una prueba de extremo a extremo confirmó que el endpoint migrado devuelve predicciones coherentes.

X. CONCLUSIONES

Auditamos un sistema de predicción de diabetes en producción y mostramos, usando únicamente la evidencia del propio proyecto, que su exactitud insignia del 97.89% no era reproducible ni honesta: provenía de una discrepancia de datos/variables y de fuga de información mediada por la HbA1c. Un nuevo *benchmark* con control de fuga de nueve modelos estableció una línea base honesta (regresión logística, ROC-AUC 0.659, MCC 0.223), que interpretamos y redespelgamos en PREDIA con un contrato de variables corregido. La lección central es metodológica: en el AA clínico, las métricas casi perfectas son una señal de alarma, y el control disciplinado de la fuga, la reproducibilidad y el reporte honesto importan más que la exactitud insignia.

XI. TRABAJO FUTURO

Las direcciones futuras incluyen: recolectar una cohorte más grande, etiquetada clínicamente y documentada; validación externa multicéntrica y temporal; calibración de probabilidades y optimización del umbral según el costo clínico (favoreciendo la sensibilidad); análisis de equidad por subgrupos de etnia y sexo; *aprendizaje federado* con preservación de la privacidad entre instituciones; y herramientas más ricas de IA explicable integradas en el flujo de trabajo del clínico.

REPRODUCIBILIDAD

Todos los artefactos (notebooks ejecutados, modelos entrenados, métricas, figuras e informes) se proporcionan en el directorio `ml-research/` con un `requirements.txt` de versiones fijadas y una semilla global de 42.

REFERENCIAS

- [1] International Diabetes Federation, “IDF diabetes atlas, 10th ed.” International Diabetes Federation, Brussels, Belgium, Tech. Rep., 2021.
- [2] S. Kaufman, S. Rosset, C. Perlich, and O. Stitelman, “Leakage in data mining: Formulation, detection, and avoidance,” *ACM Transactions on Knowledge Discovery from Data (TKDD)*, vol. 6, no. 4, pp. 1–21, 2012, doi: 10.1145/2382577.2382579
- [3] S. Kapoor and A. Narayanan, “Leakage and the reproducibility crisis in machine-learning-based science,” *Patterns*, vol. 4, no. 9, p. 100804, 2023, doi: 10.1016/j.patter.2023.100804
- [4] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324
- [5] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proc. 22nd ACM SIGKDD Int. Conf. on Knowledge Discovery and Data Mining (KDD)*, 2016, pp. 785–794, doi: 10.1145/2939672.2939785
- [6] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, “LightGBM: A highly efficient gradient boosting decision tree,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017, pp. 3146–3154.
- [7] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995, doi: 10.1007/BF00994018
- [8] T. Cover and P. Hart, “Nearest neighbor pattern classification,” *IEEE Transactions on Information Theory*, vol. 13, no. 1, pp. 21–27, 1967, doi: 10.1109/TIT.1967.1053964
- [9] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and É. Duchesnay, “Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [10] S. M. Lundberg and S.-I. Lee, “A unified approach to interpreting model predictions,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017, pp. 4765–4774.
- [11] American Diabetes Association, “Classification and diagnosis of diabetes: Standards of medical care in diabetes—2021,” *Diabetes Care*, vol. 44, no. Supplement 1, pp. S15–S33, 2021, doi: 10.2337/dc21-S002
- [12] D. Chicco and G. Jurman, “The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation,” *BMC Genomics*, vol. 21, no. 1, p. 6, 2020, doi: 10.1186/s12864-019-6413-7
- [13] A. Rashid, “Diabetes dataset,” Mendeley Data, V1, 2020, doi: 10.17632/wj9rwkp9c2.1